

AI 정보 제공과 WTP 측정의 가상편의

AI 는 가치 평가를 정확하게 하는가, 왜곡하는가?

[저자명]

[소속]

May 28, 2026

AI와 우리 — 일상에 들어온 AI의 양면

AI는 이미 우리 일상에 들어와 있다. ChatGPT에게 글을 시키고, 유튜브가 영상을 추천하고, 쇼핑몰이 “당신을 위한 상품”을 띄우고, 병원에서 진단 보조에 AI가 쓰인다.

핵심 질문: AI의 추천 한마디가 우리의 의사결정을 어떻게 바꾸는가?

좋은 면 — AI의 장점

- ▶ **정보 접근성** ↑: 전문가에게 묻기 어려운 정보를 즉시 얻음.
- ▶ **개인화 추천**: 내 건강 상태·취향 기반 맞춤 추천.
- ▶ **의사결정 보조**: 복잡한 비교·계산 대신 “한 문장 요약”.
- ▶ **알고리즘 신뢰 (Logg et al. 2019)**: 사람들은 AI 조언에 인간 전문가보다 더 큰 가중치를 부여 (WOA $d \approx 0.4$).

나쁜 면 — AI의 단점

- ▶ **앵커링 (anchoring)**: AI가 “XX,XXX 원” 말하면 그 숫자에 머리가 고정.
- ▶ **정보 과부하**: 너무 많은 정보 → 판단력 흐려짐 → 직관에 의존.
- ▶ **무비판적 수용**: “AI니까 옳겠지” — 검증 없이 따름.
- ▶ **한 번의 오류로 신뢰 붕괴 (Dietvorst et al. 2015)**: AI 실수 목격 후 AI 선택률 65% → 23%.

같은 AI인데 결과가 정반대일 수 있다 — 그렇다면 * 소비자 의사결정의 핵심인 “가치 평가” * 에 AI가 들어오면?

본 연구가 주목한 문제

양면을 가진 AI가 “가치 평가 (valuation)”에 들어오면 어떻게 될까?

일상의 예시 — 건강기능식품을 살 때

- ▶ 마트에서 건강기능식품 한 상자를 본다. “얼마면 살까?”를 고민.
- ▶ AI가 “귀하의 건강 프로파일 기준 적합도 88%, 적정 가치 30,000 원”이라 말한다.
- ▶ 그러면 내가 원래 생각했던 가치 평가가 어떻게 달라지나?

두 가지 가능성:

- ▶ **좋은 시나리오:** AI가 모호하던 효능 정보를 명확히 줘서 더 정확한 가치 평가 가능.
- ▶ **나쁜 시나리오:** AI가 제시한 “30,000 원”에 끌려가서, 실제로는 더/덜 가치 있게 평가하던 것이 왜곡됨.

문제: 어느 시나리오가 실제로 작동하는가? 그리고 그 효과는 측정에 어떤 영향을 주는가?

WTP 측정의 함정 — 가상편의 (Hypothetical Bias)

WTP (Willingness to Pay, 지불 의향): “이 상품에 얼마까지 낼 수 있나”

측정의 두 가지 방법, 그리고 둘 사이의 격차:

- ▶ **설문 (CVM):** “이 상품을 얼마에 살 의향이 있나요?” — 저비용·대규모. 단, 진짜 돈 안 냄.
- ▶ **실험경매:** 실제 입찰 + 진짜 결제. 정확하나 고비용·소규모.
- ▶ **Fox et al. (1998):** 설문 WTP 는 실제 경매의 1.5-1.8 배.
→ 사람들은 가상 상황에서 가치를 과장한다.

직관적 비유 — 카페 커피:

“5,000 원짜리 커피 살 거예요?” (설문) → “네”
실제로 5,000 원 내라고 하면? → “음, 좀 비싸네...”

이 갭이 바로 가상편의:

$$\text{Bias} = \text{WTP}_{\text{CVM}} - \text{WTP}_{\text{auction}}$$

Bias 가 작을수록 “설문” 측정이 진짜에 가깝다 → 정책·연구에 유용.

본 연구의 종속변수 = 이 Bias. AI 정보가 Bias 를 줄이는가, 늘리는가가 질문.

연구 질문 — 풀어서 설명

한 줄 RQ:

AI 개인화 정보가 WTP 측정의 가상편의를 **줄이는가**, 아니면 **왜곡**시키는가?

풀어서:

- ▶ 소비자에게 AI가 만든 개인화 정보를 보여주면,
- ▶ 설문 WTP와 실제 경매 WTP의 차이 (= 가상편의)가
- ▶ 어떻게 변하는가? 그리고 왜 변하는가?

4개 세부 질문:

- ▶ **Q1.** AI 개인화 정보 vs 일반 정보 — 정보원 효과.
- ▶ **Q2.** 정보량이 많을수록 갭이 줄어드나, 아니면 역전되나?
- ▶ **Q3.** AI × 고정보량에서 앵커링·과부하·신뢰 편향 때문에 갭이 오히려 커지는가?
- ▶ **Q4.** 인지능력에 따라 효과가 달라지나? (탐색적)

핵심 기여: Fox et al. (1998) CVM-X 라인의 21세기 AI 재해석 — AI를 가상편의 측정의 calibration tool로 평가한 최초의 실험경제 연구.

가설 A — AI가 정확도를 높임 (Bayesian 업데이트)

직관: “친구가 추천하면 더 잘 사는 느낌”

- ▶ 건강기능식품의 효능은 직접 검증 어려움 → 불확실성 큼.
- ▶ AI가 “귀하에게 적합도 88 %, 4 주 후 효과 나타남” 알려줌 → 불확실성 ↓.
- ▶ 불확실성이 줄면 진짜 가치에 더 가깝게 입찰 가능 → 경매 WTP ↑.
- ▶ 따라서 **Bias** (= 설문 - 경매) ↓.

이론적 뒷받침 — Zhao & Kling (2001):

- ▶ 경매에는 commitment cost 존재 (진짜 돈 거니까) → 정보 정밀도 ↑가 입찰에 직결.
- ▶ 설문은 commitment cost ≈ 0 (가상) → 정보의 한계 효과 제한.

예측: $\beta_{\text{auction}} > \beta_{\text{CVM}}$ — 경매가 정보에 더 크게 반응.

가설 B — AI가 왜곡 (3 가지 행동경제 채널)

B-1. 앵커링 (Anchoring):

- ▶ AI가 “적정 가치 30,000 원” 이라 말하면 → 그 숫자가 머리에 못박힘.
- ▶ 진짜 가치가 25,000 원이든 35,000 원이든, 입찰가가 30,000 원으로 끌려감.
- ▶ 측정: $\text{AnchorDev} = \text{Bid} - \text{AI 제시가}$. 0에 가까울수록 강한 앵커링.

B-2. 정보 과부하 (Information Overload):

- ▶ AI 상세 정보 (성분·임상·적합도 %) → 처리 용량 초과.
- ▶ 깊이 생각 못 함 → “직감”에 의존 (System 1) → 입찰 분산 ↑ (mean은 안 움직임).
- ▶ Lee et al. (2020): 인공지능력 낮은 그룹의 입찰 분산이 약 3 배.

B-3. AI 신뢰 편향 (Algorithm Appreciation ↔ Aversion):

- ▶ 무비판적 수용 (Logg 2019): AI 말을 인간 전문가보다 더 신뢰 → 입찰이 AI 제시가에 끌려감.
- ▶ 또는 회피 (Dietvorst 2015): AI 한 번 틀리면 거의 안 따름.
- ▶ 본 연구 Phase 1 중립화 (다음 슬라이드) 로 Appreciation default 유지.

예측: 채널 B 작동 시 Bias가 불규칙하게 변하거나 오히려 커짐.

4 채널 분해도 — 어느 셀이 어느 채널을 식별하나?

채널	메커니즘	측정 가능 셀	식별 신호
A. Bayesian	불확실성 ↓ → 진짜 가치 수렴	T1·T3 (정보 추가) + SUR 분석	$\beta_{auc} > \beta_{CVM}$
B-1. 앵커링	AI 숫자가 입찰가 기준점	T2 (시장가), T3·T4 (AI 추정가)	AnchorDev ≈ 0
B-2. 과부하	처리 용량 초과 → System 1	T2·T4 (高) vs T1·T3 (低)	입찰 분산 ↑ (mean 무관)
B-3. AI 신뢰	“AI 니까 맞겠지” 무비판	T3·T4 (AI) vs T1·T2 (Generic)	“AI 신 뢰 도” 점 수 + Pre_Aversion

핵심 식별 logic:

- ▶ T2 vs T4: 같은 정보량 + anchor 둘 다 있음. 차이는 AI source 여부. → **AI 고유 앵커링** (B-1 with B-3) 분리.
- ▶ T1 vs T3: 같은 정보량, 차이는 **개인화** + AI source. → AI 개인화 순수 효과.
- ▶ T3 vs T4: 같은 AI source, 차이는 정보량. → 과부하 임계점.

채널 A와 B-1은 관측적으로 일부 겹침 → Mediation 분석 (Slide 16) 으로 상대 강도 추정.


어느 쪽이 이길까? — 5-arm × 채널 예측표

조건	채널 A 예측	채널 B 예측	핵심 비교
T0: 정보 없음 (기준선)	—	—	모든 비교의 baseline
T1: Generic × Low	갭 소폭 ↓	변화 미미	T1 vs T0
T2: Generic × High	갭 ↓	과부하 분산 ↑	T2 vs T1
T3: AI × Low	갭 ↓ (개인화)	Appreciation 변동	T3 vs T1
T4: AI × High	갭 더 ↓	앵커링 + 과부하 + 편향 → 갭 ↑?	T4 vs T3, T4 vs T2

핵심 격전지: T4 (AI × High).

- ▶ AI의 **좋은 면**이 강하면: 정확도 ↑ → Bias 감소.
- ▶ AI의 **나쁜 면**이 강하면: 앵커링·과부하·맹신 결합 → Bias 증가.
- ▶ **결과가 음수든 양수든 해석 가능** — 이게 본 연구의 강점.

실험 설계 (1) — 2-Phase 구조



Phase 1 중립화의 3 가지 역할: (1) 랜덤 배정 검증, (2) 경매 숙련도 균등화 (Plott-Zeiler 2005), (3) AI 오류 노출 차단 (Algorithm Aversion 회피, Dietvorst 2015).

실험 설계 (2) — 5 개 처리 집단

	정보량 低 (요약)	정보량 高 (상세)
Generic	T1 ($n=50$) 비개인화 요약	T2 ($n=50$) 비개인화 상세 + 시장가
AI	T3 ($n=50$) AI 개인화 요약 + AI 추정가	T4 ($n=50$) AI 개인화 상세 + AI 추정가

+ T0 ($n=50$): 기본 설명만 (100 자) — 정보 없음 기준선. 총 $n = 250$.

식별 핵심 비교 (Slide 8 4 채널 매핑 참고):

- ▶ T1 vs T3: AI 개인화 순수 효과 (정보량 통제).
- ▶ T1 vs T2: 정보량 효과 (비-AI 통제, 과부하 임계점).
- ▶ T3 vs T4: 정보량 효과 (AI 통제, 앵커링/과부하 임계점).
- ▶ T2 vs T4: 같은 고정정보량 + anchor 에서 AI source 효과 (= AI 고유 앵커링).
- ▶ T0 vs (T1...T4): 정보 유무 전체 효과.

실험 설계 (3) — 제품: 건강기능식품

선정: 건강기능식품 (Dietary Supplement) — 예: 프로바이오틱스 / 오메가-3 / 멀티비타민 1개월분.

선정 근거 (4 가지):

- ▶ **신뢰재 (credence good):** 효능을 직접 검증하기 어려움 → AI 정보의 불확실성 감소 효과가 의미를 가짐 (채널 A 작동 조건).
- ▶ **AI 개인화 자연스러움:** 건강 상태·식이·부족 영양소 기반 추천이 실제 서비스로 존재 → Algorithm Appreciation 발생 조건.
- ▶ **시장 가격 존재:** 약 30,000 원/월 수준 → 실험 경매 가격대 자연스러움 + Anchor 설계 가능.
- ▶ **이중 가상 문제 없음:** 배양육 등과 달리 국내에서 실제로 살 수 있는 상품 → 외적 타당성.

단, 순수 credence 가 아닌 “credence-experience 혼합재” (소화 개선은 1-2 주 체감). → 구매 경험 빈도를 채널 A 강도의 moderator 로 격상 (탐색적).

실험 설계 (4) — AI 메시지 5 가지 비교

Arm	개인화 여부	핵심 내용 (예시)	Anchor
T0 (기준)	없음	“프로바이오틱스 30 포, 1개월분.” (100 자)	없음
T1 (Gen×Lo)	없음	효능 요약 3 문장 + 식약처 인증	없음
T2 (Gen×Hi)	없음	성분표 + 임상 근거 + 주의사항 (1 쪽)	시장 평균가 명시 (30,000 원)
T3 (AI×Lo)	건강 프로파일 참조	“귀하 적합도 87%, 부족 영양소 충족” (3 문장)	AI 추정가 명시 (±20% 변이)
T4 (AI×Hi)	프로파일 + 개인 점수	T3 + 성분별 적합도 + 비교 순위 + 발 현 시기 + 반응률 (1 쪽)	AI 추정가 명시 (±20%)

AnchorDev 직접 측정:

- ▶ T3/T4: $\text{AnchorDev} = \text{Bid} - \text{AI_price}$. 0 에 가까울수록 강한 앵커링.
- ▶ T2: $\text{AnchorDev}_{\text{gen}} = \text{Bid} - \text{Generic_price}$ (단일 reference).
- ▶ AI 고유 앵커링 = $\text{AnchorDev}_{\text{T4}} - \text{AnchorDev}_{\text{T2}}$ (T4 와 T2 anchor 모두 명시, 차이는 AI source 뿐).
- ▶ **AI 추정가의 ±20% 변이** (피험자별 무작위) → 앵커링 방향성도 검증.

실험 설계 (5) — 경매 방식과 절차

경매: Random n -th Price Auction (Shogren et al. 2001)

- ▶ 입찰자들의 입찰가를 순위 매김 → 무작위로 n 추출 → 상위 $(n - 1)$ 명이 n 번째 가격에 구매.
- ▶ 표준 SPA(2 등 가격 경매)의 “low-value 입찰자 무성의” 문제를 회피 (off-margin engagement).
- ▶ 진짜 돈 결제 → 가상편의의 “경매 측” 측정에 적합.

전체 절차 (총 75-80 분):

1. **사전 설문 (10 분):** 건강 프로필, CRT, AI 사용 경험, Pre_Aversion.
2. **Phase 1 (25 분):** 메커니즘 교육 + 연습 3R + Induced 경매 5R.
3. **Phase 2 (30 분):** 처치 자료 (T0-T4) → **CVM 응답** → **Filler task (5 분)** → **Random n -th price 경매 5R.**
4. **사후 설문 (10 분):** Manipulation check, AI 신뢰도, 앵커링·과부하 자기보고.

Filler task 의 역할: CVM 응답이 경매의 “내적 anchor”로 작동하는 순서 효과 차단 (이중 앵커링 의허 통제)

분석 (1) — 주 분석: 2×2 팩토리얼

Phase 2 주 회귀:

$$\begin{aligned}\text{Bias}_i &= \alpha + \delta_{\text{src}} \cdot \text{AI}_i + \delta_{\text{amt}} \cdot \text{High}_i \\ &\quad + \delta_{\text{int}} \cdot (\text{AI}_i \times \text{High}_i) + \gamma \cdot \text{Pre_Aversion}_i + \delta X_i + \varepsilon_i\end{aligned}$$

핵심 가설 (해석 가이드):

- ▶ $\delta_{\text{src}} < 0$: AI 개인화가 갭 **감소** → 채널 A 작동.
- ▶ $\delta_{\text{amt}} < 0$: 정보량 ↑가 갭 **감소** → 채널 A 작동.
- ▶ $\delta_{\text{int}} > 0$: AI × High 에서 갭 **증가** → **채널 B 지배** (앵커링/과부하/편향 결합).

본 연구의 핵심 시그널: 결과가 $\delta_{\text{int}} > 0$ 이면 “AI 정보가 많아질수록 오히려 위험”.
 $\delta_{\text{int}} \leq 0$ 이면 “AI 정보가 가상편의 측정의 도구로 유용”.

분석 (2) — 두 가설 어떻게 구분하나

도구 1 — SUR 병렬 회귀: CVM과 경매 WTP의 *비대칭 이동* 검정.

- ▶ $\beta_{\text{auc}} > \beta_{\text{CVM}} \rightarrow$ 경매가 더 반응 = 채널 A (Bayesian).
- ▶ $\beta_{\text{auc}} \approx \beta_{\text{CVM}} \rightarrow$ 두 WTP 동일 이동 = 이중 앵커링 (Filler로 부분 통제).

도구 2 — AnchorDev 직접 측정:

- ▶ $|\text{AnchorDev}| \approx 0 \rightarrow$ 입찰이 AI 제시가에 수렴 = 강한 앵커링.
- ▶ T2 (시장가 anchor)과 T4 (AI 추정가 anchor) 비교 $\rightarrow$ AI 고유 앵커링 분리.

도구 3 — 경쟁 매개 분석 (Competing Mediation):

$$\text{WTP}_{\text{auc},i} = \alpha + \gamma T_i + a_A \text{Uncertainty_dec}_i + a_B \text{Anchoring_score}_i + \delta X_i + \varepsilon_i$$

$\rightarrow$ 채널 A vs B-1의 상대 강도 추정 (둘이 관측적 등가이므로 완전 분리 불가, 상대만).

Reframing: “채널의 완전 분리” $\rightarrow$ “상대적 크기 추정 및 조건부 우세 판별.”

분석 (3) — Benchmark 내부 (조작 점검 + 이질성)

내부 Benchmark 2 가지 — 본 실험 내부에서 측정·검증.

(A) Phase 1 Induced Deviation — 랜덤 배정 검증:

- ▶ Phase 1에서는 모든 집단 같은 조건 (AI 정보 없음).
- ▶ 측정: $\text{Deviation}_i = |\text{Bid}_i - \text{TrueValue}_i|$.
- ▶ 예측: $\beta_1 = \beta_2 = \beta_3 = \beta_4 \approx 0$ (집단 간 차이 없음).
- ▶ → 차이가 있으면 randomization 실패 확인 (Phase 2 결과 신뢰성에 critical).

(B) Lee et al. (2020) CRT 분산비 — 채널 B-2 검증:

- ▶ Lee et al. 발견: 인지능력 낮은 그룹의 입찰 분산이 약 3 배 (induced value 경매).
- ▶ 본 연구: 처치별 $\text{Var_ratio} = \text{SD}_{\text{CRT-low}} / \text{SD}_{\text{CRT-high}}$ (Phase 2 경매 WTP).
- ▶ 예측 (채널 B-2 작동 시): T4(AI × High)에서 Var_ratio가 T0보다 증가.
- ▶ → “AI 상세 정보가 저-CRT 집단의 입찰 불안정성을 증폭” 직접 검증.

내부 benchmark = 본 실험의 자기 통제 검증. 결과 신뢰성의 핵심.

분석 (4) — Benchmark 외부 (선행연구 효과 크기)

외부 Benchmark — 선행연구의 효과 크기를 본 연구 결과의 맥락으로.

선행연구 (외부 기준)	외부 효과 크기	본 연구 비교점
Choi et al. (2018) 한국 쌀 등급 정보	WTP 이동 $\pm 15\%$	T1→T3 또는 T2→T4 효과가 이 범위와 비교 가능한지
Tuncel & Hammitt (2014) WTP/WTB 메타분석	WTB/WTP ≈ 3	본 연구 Bias 절대 크기가 메타분석 표준 어디에 위치하는지
Logg et al. (2019) AI 가중치 (WOA)	$d \approx 0.4$	T3·T4 처치 효과가 Algorithm Appreciation 효과 범위 내인지
Fox et al. (1998) CVM-X 보정계수	0.55-0.69	본 연구 T0 의 Bias 가 Fox baseline 과 일관되는지

보고 방식:

- ▶ Discussion 섹션에서 “본 연구 효과 = Choi 효과의 X 배 / Logg 효과의 Y 배” 형식.
- ▶ 단, 서로 다른 표본·제품·시기이므로 illustrative comparison 으로 framing.
- ▶ Cheap talk (List 2001) 와의 이론적 구분은 별도 단락에서.

분석 (5) — 이질성과 다중비교 위계

이질성 분석: $2 \times 2 \times \text{CRT}$ (탐색적, 사전등록):

- ▶ Bergman et al. (2010): CRT $\times$ 앵커링 비유의 ($p = 0.526$). CAT(인지능력)은 유의 ($p = 0.043$).
- ▶ $\rightarrow$ CRT 이질성은 confirmatory *아님*, 탐색적 발견으로만 보고.
- ▶ $\varphi_3 \approx 0$ **이어도 “미탐지 (inconclusive)”로 표현** ($\neq$ “Bergman 과 일관”).

구매 경험 Moderator (탐색적): $\psi \cdot (\text{AI}_i \times \text{Experience_high}_i) \rightarrow$ 경험자에게 AI 효과가 약하면 credence 가정 부분 약화.

다중비교 위계 (사전등록):

- ▶ **1 단계 Confirmatory:** 2×2 의 3 개 계수 $\rightarrow$ Holm correction.
- ▶ **2 단계 Secondary:** SUR + 4 경로 mediation $\rightarrow$ FDR (Benjamini-Hochberg).
- ▶ **3 단계 Exploratory:** φ_3 (CRT), ψ (Experience) $\rightarrow$ 보정 없음, 탐색적 보고.

사전등록 OSF/AsPredicted 에 이 3 단계 위계를 명시 $\rightarrow$ p-hacking 우려 사전 차단.

예상 기여, 한계, 일정

기여 4 가지:

1. AI 정보의 양면성 최초 실증 (채널 A vs B 의 3 개 sub-channels).
2. 2×2 팩토리얼로 정보원 $\times$ 정보량 효과 분리.
3. AI 가격 앵커의 WTP 효과 직접 정량화 (가상편의 맥락 최초).
4. Fox et al. (1998) CVM-X 라인의 21 세기 AI 재해석 — 새로운 실험 디자인 방법.

한계 3 가지:

- ▶ 실험실 $\rightarrow$ 현장 외적 타당성 약함 (lab credence-good 한정).
- ▶ AI 금전 anchor 명시 (T3/T4) 가 ecological validity 약화 (실제 AI 는 가격 직접 제시 드뭅).
- ▶ 채널 A 와 B-1 의 관측적 등가성 $\rightarrow$ 완전 분리 불가 (mediation 으로 상대 크기만).

일정 (잠정):

- ▶ M+0-2: AI 메시지 prototype v2 + IRB 신청 + 사전등록 (OSF/AsPredicted).
- ▶ M+2-3: Pilot ($n \approx 30$) $\rightarrow$ 메시지·Anchor 캘리브레이션.
- ▶ M+3-5: Main study 실행 ($n = 250$).
- ▶ M+5-7: 데이터 분석 + 논문 작성.

Future Work: induced value setting 에서 AI source effect 를 직접 측정하는 companion study (Lee et al.

2022, 진행 중)

Thank you!